

P1 pairwise Cohen's κ — Condition A (dev split, run 0)

gpt-4o-mini

	RAGTruth-Sum				
multivon-eval	1.00	0.00	0.00	0.00	0.21
DeepEval	0.00	1.00	0.00	0.00	0.00
RAGAS	0.00	0.00	1.00	0.00	0.00
TruLens	0.00	0.00	0.00	1.00	0.00
Opik	0.21	0.00	0.00	0.00	1.00

median $\kappa=0.00$ [0.00, 0.00]

	HaluEval-Sum				
multivon-eval	1.00	0.02	0.20	0.19	0.56
DeepEval	0.02	1.00	-0.02	-0.02	0.02
RAGAS	0.20	-0.02	1.00	0.69	0.30
TruLens	0.19	-0.02	0.69	1.00	0.21
Opik	0.56	0.02	0.30	0.21	1.00

median $\kappa=0.19$ [0.08, 0.30]

	HaluEval-QA				
multivon-eval	1.00	0.10	0.38	0.49	0.51
DeepEval	0.10	1.00	0.18	0.28	0.30
RAGAS	0.38	0.18	1.00	0.57	0.38
TruLens	0.49	0.28	0.57	1.00	0.65
Opik	0.51	0.30	0.38	0.65	1.00

median $\kappa=0.38$ [0.27, 0.51]

Cohen's κ

claude-haiku-4.5

	RAGTruth-Sum				
multivon-eval	1.00	0.01	-0.08	0.01	0.01
DeepEval	0.01	1.00	-0.02	-0.01	0.27
RAGAS	-0.08	-0.02	1.00	-0.02	-0.01
TruLens	0.01	-0.01	-0.02	1.00	-0.02
Opik	0.01	0.27	-0.01	-0.02	1.00

median $\kappa=-0.01$ [-0.03, 0.01]

	HaluEval-Sum				
multivon-eval	1.00	0.01	0.14	0.20	0.38
DeepEval	0.01	1.00	-0.02	-0.02	0.06
RAGAS	0.14	-0.02	1.00	0.56	0.32
TruLens	0.20	-0.02	0.56	1.00	0.53
Opik	0.38	0.06	0.32	0.53	1.00

median $\kappa=0.17$ [0.08, 0.26]

	HaluEval-QA				
multivon-eval	1.00	0.30	0.25	0.62	0.64
DeepEval	0.30	1.00	0.07	0.38	0.35
RAGAS	0.25	0.07	1.00	0.21	0.35
TruLens	0.62	0.38	0.21	1.00	0.62
Opik	0.64	0.35	0.35	0.62	1.00

median $\kappa=0.35$ [0.24, 0.48]

1.0

0.8

0.6

0.4

0.2

0.0

-0.2