

P1 pairwise Cohen's κ — Condition B (dev split, run 0)

gpt-4o-mini

	RAGTruth-Sum				
multivon-eval	1.00	0.12	0.42	0.05	0.00
DeepEval	0.12	1.00	0.19	0.07	0.00
RAGAS	0.42	0.19	1.00	0.16	0.00
TruLens	0.05	0.07	0.16	1.00	0.00
Opik	0.00	0.00	0.00	0.00	1.00

median $\kappa=0.06$ [0.00, 0.15]

	HaluEval-Sum				
multivon-eval	1.00	0.35	0.51	0.37	0.56
DeepEval	0.35	1.00	0.50	0.15	0.25
RAGAS	0.51	0.50	1.00	0.24	0.39
TruLens	0.37	0.15	0.24	1.00	0.37
Opik	0.56	0.25	0.39	0.37	1.00

median $\kappa=0.37$ [0.27, 0.47]

	HaluEval-QA				
multivon-eval	1.00	0.10	0.36	0.49	0.49
DeepEval	0.10	1.00	0.16	0.32	0.36
RAGAS	0.36	0.16	1.00	0.46	0.43
TruLens	0.49	0.32	0.46	1.00	0.63
Opik	0.49	0.36	0.43	0.63	1.00

median $\kappa=0.40$ [0.29, 0.51]Cohen's κ

claude-haiku-4.5

	RAGTruth-Sum				
multivon-eval	1.00	0.16	0.31	0.41	0.44
DeepEval	0.16	1.00	-0.02	0.12	0.14
RAGAS	0.31	-0.02	1.00	0.31	0.29
TruLens	0.41	0.12	0.31	1.00	0.61
Opik	0.44	0.14	0.29	0.61	1.00

median $\kappa=0.30$ [0.16, 0.41]

	HaluEval-Sum				
multivon-eval	1.00	0.43	0.60	0.60	0.43
DeepEval	0.43	1.00	0.41	0.36	0.42
RAGAS	0.60	0.41	1.00	0.79	0.58
TruLens	0.60	0.36	0.79	1.00	0.48
Opik	0.43	0.42	0.58	0.48	1.00

median $\kappa=0.46$ [0.36, 0.61]

	HaluEval-QA				
multivon-eval	1.00	0.31	0.58	0.62	0.60
DeepEval	0.31	1.00	0.24	0.33	0.40
RAGAS	0.58	0.24	1.00	0.43	0.58
TruLens	0.62	0.33	0.43	1.00	0.58
Opik	0.60	0.40	0.58	0.58	1.00

median $\kappa=0.50$ [0.38, 0.60]